



Проверка ответа на патоген по иммунному репертуару

Андреева Анна
Кондратюк Наталья
Пискунова Ольга
Филимонова Арина


Наивный подход

Иммунный репертуар каждого пациента может быть избыточен и не обязательно говорит о текущем заболевании.

В итоговой таблице почти у всех пациентов присутствуют антигены CMV и/или EBV, это действительно распространенные вирусы, они присутствуют более чем у 90% населения.

	count		count
antigen.species		antigen.species	
CMV	645	CMV	917
EBV	211	EBV	260
InfluenzaA	150	SARS-CoV-2	229
SARS-CoV-2	115	InfluenzaA	209
HomoSapiens	87	HomoSapiens	145
HIV-1	67	HIV-1	94
DENV	31	DENV	52
YFV	28	HCV	47
HCV	27	YFV	26
synthetic	16	Mtb	12
TriticumAestivum	16	TriticumAestivum	11
Influenza B	10	Influenza B	10
Mtb	6	PlasmodiumFalciparum	6
PlasmodiumFalciparum	6	LCMV	4
HTLV-1	4	AdV	3
LCMV	3	HTLV-1	3
MCMV	2	MCMV	2
Trypanosoma cruzi	1	HCoV-HKU1	1
HPV	1		

Предобработка данных пациентов



Нуклеотидные последовательности с небольшим количеством прочтений могут представлять собой ошибочные варианты высокочастотный клонотипов => избавляемся от шума, берем данные с достаточно большим количеством прочтений

Зависимость количества прочтений от номера строки для Wide Pirate

Приводим данные всех пациентов к единому формату

Для дальнейшей работы пригодятся столбцы с аминокислотной последовательностью, частотой попадания последовательности, числом прочтений и V- и J-генами.

	CDR3.amino.acid.sequence	Read.proportion	Read.count	bestVGene	bestJGene
0	CASSNSDRTYGDNEQFF	2.243318e-03	4120	TRBV6-2	TRBJ2-1
1	CASSRRHLGNTGELFF	1.948747e-03	3579	TRBV7-2	TRBJ2-2
2	CASSPSTDTQYF	1.799011e-03	3304	TRBV27	TRBJ2-3
3	CASSSRGLANTQYF	1.786487e-03	3281	TRBV12-4	TRBJ2-3
4	CASSEGRSNQPQHF	1.583391e-03	2908	TRBV2	TRBJ1-5
...	...	...	...	...	...
336424	CSVEDLGRHSNYGYTF	5.444947e-07	1	TRBV29-1	TRBJ1-2
336425	CSVEDLGASGYTF	5.444947e-07	1	TRBV29-1	TRBJ1-2
336426	CSVEDLGASSGRRETQYF	5.444947e-07	1	TRBV29-1	TRBJ2-5
336427	CSVEDLGSRTAEFF	5.444947e-07	1	TRBV29-1	TRBJ1-1
336428	NaN	5.444947e-07	1	NaN	NaN

Кластеризация данных



Использовалась кластеризация с использованием расстояния Левенштейна. В нашем случае $\text{max_distance} = 1$.

Сортировка по количеству последовательностей в кластере

Ищем самые большие кластеры.

Таким образом, находим те последовательности, которые имеют наибольшее количество отличающихся на 1 аминокислоту.

	Cluster	Total Read Proportion	Sequence Count
172	173	0.000432	8
2	3	0.001986	7
142	143	0.000316	6
229	230	0.000217	6
232	233	0.000210	4
...	...	...	...
759	760	0.000039	1
758	759	0.000039	1
757	758	0.000039	1
756	757	0.000039	1
2215	2216	0.000017	1

Подсчет Total Read Proportion

Сортировка по этому параметру для дальнейшей оценки кластеров с самыми часто встречающимися последовательностями

	Cluster	Total Read Proportion	Sequence Count
2	3	0.001986	7
4	5	0.001607	2
172	173	0.000432	8
142	143	0.000316	6
46	47	0.000305	2
...	...	...	...
1524	1525	0.000042	2
1405	1406	0.000042	2
1590	1591	0.000041	2
1582	1583	0.000039	2
2005	2006	0.000035	2

Выбор кластера

	Cluster	Total Read Proportion	Sequence Count	count
0	23	0.001229	5	1
1	46	0.000731	10	10
2	74	0.000305	4	1
3	422	0.000257	13	3
4	655	0.000244	10	2
5	216	0.000146	2	2
6	134	0.000142	1	1
7	404	0.000134	6	2
8	151	0.000132	1	1
9	239	0.000107	2	1
10	209	0.000103	1	1
11	334	0.000073	1	2
12	354	0.000070	1	2
13	589	0.000047	1	1
14	636	0.000043	1	3
15	674	0.000041	1	1
16	1606	0.000040	2	2

Cluster	count
3	16
816	2
785	2
1893	2
411	1
722	1
733	1
734	1
703	1
559	1
1982	1

Объединяем таблицу с обработанными данными пациента с таблицей с антигенами по параметрам "CDR3.amino.acid.sequence", "BestVGene" и "BestJGene".

Таким образом, остаются только те последовательности, которые есть в обеих таблицах

Обработка выбранного кластера

Из оставшихся кластеров выбираем один и определяем, к какому заболеванию он относится

✓ Обработка с учётом V и J генов

```
[ ] full_vj = full.loc[(full['bestVGene'].str[:7] == full['v.segm'].str[:7]) & (full['bestJGene'].str[:7] == full['j.segm'].str[:7]) & (full_vj
```

3.amino.acid.sequence	Read.proportion	bestVGene	bestJGene	v.segm	j.segm	mhc.class	species	antigen.species	antigen.gene
CSAPTSGGPNEQFF	0.000467	TRBV20-1	TRBJ2-1	TRBV20-1*01	TRBJ2-1*01	MHCI	HomoSapiens	YFV	NS4B

yellow fever virus

Результаты для пациента Mengsk

	count
antigen.gene	
BZLF1	24
MLANA	11
IE1	8
EBNA4	6
BMLF1	2
EBNA3A	2
M	2
Gag	2
Spike	1

Cluster	CDR3.amino.acid.sequence	Read.proportion	bestVGene	bestJGene	v.segm	j.segm	mhc.class	species	antigen.species	antigen.gen
3	CAIGTGDSNQPHF	0.009478	TRBV10-3	TRBJ1-5	TRBV10-3*01	TRBJ1-5*01	MHCI	HomoSapiens	EBV	BZLF
3	CAIGTGDSNQPHF	0.002710	TRBV10-3	TRBJ1-5	TRBV10-3*01	TRBJ1-5*01	MHCI	HomoSapiens	EBV	BZLF
3	CATGTGDSNQPHF	0.002096	TRBV10-3	TRBJ1-5	TRBV19*01	TRBJ1-5*01	MHCI	HomoSapiens	EBV	EBNA
3	CATGTGDSNQPHF	0.002096	TRBV10-3	TRBJ1-5	TRBV19*01	TRBJ1-5*01	MHCI	HomoSapiens	CMV	IE
3	CATGTGDSNQPHF	0.002096	TRBV10-3	TRBJ1-5	TRBV10-3*01	TRBJ1-5*01	MHCI	HomoSapiens	EBV	BZLF
3	CAISTGDSNQPHF	0.002006	TRBV10-3	TRBJ1-5	TRBV10-3*01	TRBJ1-5*01	MHCI	HomoSapiens	CMV	IE
3	CAISTGDSNQPHF	0.002006	TRBV10-3	TRBJ1-5	TRBV10-3*01	TRBJ1-5*01	MHCI	HomoSapiens	HomoSapiens	MLAN

Результаты и обсуждение

Пациент	Диагноз	Иммунитет	уверенность(доля от всех кластеров(по total read prop) * доля от всех антигенов)
Barracuda	CMV		0.5546 или 55.5%
Boss	HIV-1	CMV	0.2563 или 25.6%
Dance_Till_Dead	CMV	EBV, (HomoSapiens)	0.0333 или 3.3%
FEV_Reject	InfluenzaA	CMV, EBV	0.315 или 31.5 %
Johny	SARS-CoV-2	CMV	0.067 или 6.7%
King_Charles	CMV		0.1784 или 17.8%
Lucky_Number_5	YFV	CMV, EBV	0.0115 или 1.15%
Lychelle	CMV	HomoSapiens	0.0658 или 6.6%
Matchstick_Man	EBV		0.5715 или 57.2%
Mengsk	MLANA	CMV, EBV	0.1814 или 18.1%
Pavlina_Grey	InfluenzaA	CMV	0.1969 или 19.7%
Starry Sky	YFV		0.4967 или 49.7%
Wide Pirate	CMV	EBV	0.1062 или 10.6%
Wing_And_A_Prayer	WT-1	CMV	0.3059 или 30.6%